



UNIVERSIDAD DE EXTREMADURA

ESCUELA POLITÉCNICA

INGENIERÍA INFORMÁTICA EN INGENIERÍA DEL
SOFTWARE

TRABAJO FIN DE GRADO

**Optimización de las emisiones de CO₂ en
redes definidas por software mediante
algoritmos bioinspirados**

Santiago Rodríguez-Arias Martínez-Berná
Convocatoria, 2026



Escuela Politécnica

UNIVERSIDAD DE EXTREMADURA

ESCUELA POLITÉCNICA

INGENIERÍA INFORMÁTICA EN INGENIERÍA DEL
SOFTWARE

TRABAJO FIN DE GRADO

**Optimización de las emisiones de CO₂ en
redes definidas por software mediante
algoritmos bioinspirados**

Autor: Santiago Rodríguez-Arias Martínez-Berná

Tutor: Jaime Galán Jiménez

Co-Tutor: José Antonio Gómez de la Hiz

Resumen

A día de hoy, las redes de comunicaciones son un componente esencial en la vida diaria de las personas y en el funcionamiento de las empresas. El aumento del tráfico de datos ha crecido de forma exponencial, llegando a multiplicarse por 80 desde 2007 hasta 2023 [1]. Aunque el crecimiento del consumo energético no es proporcional al aumento del tráfico de datos, pues apenas se ha duplicado, esto no significa que no haya un impacto ambiental significativo. Se estima que las redes de comunicaciones representan aproximadamente el 1% del consumo eléctrico mundial y alrededor del 1,4% de las emisiones globales de CO_2 . Y estos datos no van a hacer más que aumentar debido al auge de las Inteligencias Artificiales (IA) y los grandes centros de procesamiento de datos. Por tanto, es fundamental buscar soluciones que permitan optimizar el uso de las redes para reducir su impacto ambiental.

En este trabajo se propone una solución basada en redes definidas por software (SDN) y algoritmos bioinspirados para optimizar las emisiones de CO_2 asociadas al uso de las redes de comunicaciones. Más concretamente, se parte de los avances expuestos en [2], donde los autores proporcionan una fórmula que permite calcular las emisiones de CO_2 de las redes cableadas en función del tráfico de datos y el consumo energético de los dispositivos de red. Con esta fórmula en mente, se ha modelado una función de optimización que se usará en un algoritmo de optimización por enjambre de partículas (PSO) para encontrar la configuración de red que minimice las emisiones de CO_2 .

Específicamente, en este trabajo se presentan dos versiones del algoritmo, en una de ellas se deja de evaluar una solución si esta no cumple alguna de las restricciones, mientras que en la otra se penalizan las soluciones que no cumplen dichas restricciones. En cuanto a

las pruebas, se estudian cómo diferentes técnicas de enrutamiento, el aumento del tráfico y la escalabilidad de la topología de red afectan a las emisiones de CO_2 .

Palabras clave: SDN, enrutamiento consciente de carbono.

Abstract

EL RESUMEN EN INGLÉS

Keywords: Most important or descriptive words, separated by commas.

Índice general

1. Introducción	1
2. Objetivos y Contribuciones	5
2.1. Objetivos	5
2.2. Contribuciones	7
3. Estado del Arte	8
4. Metodología	9
5. Descripción del Algoritmo Propuesto	10
5.1. Elección de la Técnica de Optimización	10
5.2. <i>Particle Swarm Optimization</i>	12
5.3. Parámetros de PSO	13
5.3.1. Partícula	13
5.3.2. Función objetivo	14
5.3.3. Velocidad	14
5.3.4. Posición	14
5.3.5. Coeficiente de inercia	15
5.3.6. Coeficiente cognitivo	15
5.3.7. Coeficiente social	16
5.3.8. Número de vecinos	16
5.3.9. Dimensiones del espacio de búsqueda	16
5.4. Aproximación al Problema	17

5.4.1.	Estrategias de manejo de restricciones	18
5.5.	Implementación y Desarrollo del Algoritmo	19
5.5.1.	Configuración de las partículas	19
5.5.2.	Iteraciones	22
5.5.3.	Coeficientes cognitivo y social	23
5.5.4.	Inercia, vecinos y dimensiones del espacio de búsqueda	24
5.5.5.	Función objetivo y pseudocódigo	25
6.	Pruebas y Resultados	29
6.1.	Detalles de la implementación	29
6.2.	Topologías utilizadas	30
6.3.	Definición de las pruebas	31
6.4.	Resultados de Abilene	32
6.4.1.	Emisiones de cada matriz de tráfico	32
6.4.2.	Emisiones después del apagado de enlaces	33
6.4.3.	Tiempos de ejecución	36
6.4.4.	Porcentaje de enlaces apagados	37
6.4.5.	Ocupación de los enlaces tras el apagado	37
6.5.	Resultados de Nobel y Geant	37
6.6.	Análisis de Germany y limitaciones encontradas	37
7.	Conclusiones y Trabajos Futuros	38
	Anexos	39
	A. Acrónimos	40
	Bibliografía	41

Índice de tablas

Índice de figuras

1.1. Esquema de redes SDN	3
5.1. Diagrama de flujo de PSO	12
5.2. Función sigmoide	17
5.3. Ejemplo sencillo PSO	20
5.4. Barrido partículas Abilene	21
5.5. Barrido partículas Abilene con inicialización controlada	22
5.6. Barridos iteraciones Abilene	23
5.7. Esquema consumo router	26
6.1. Topología Abilene	32
6.2. Emisiones máximas Abilene	33
6.3. Resultados Abilene PSO 200p 1200i 20runs	33
6.4. Resultados Abilene PSO 200p 1200i 100runs	34
6.5. Resultados Abilene PSO VCH 200p 1200i 20runs	35
6.6. Resultados Abilene PSO VCH 100p	35
6.7. Tiempos ejecución Abilene	36

Capítulo 1

Introducción

Cuando en 1969, J. C. R. Licklider, un científico de la computación estadounidense, consiguió conectar el Instituto de Investigación de Stanford con la Universidad de California en Los Ángeles [3], no podía imaginar en lo que llegaría a convertirse esa conexión. En ese momento, la idea de compartir recursos informáticos entre dos instituciones parecía revolucionaria, pero hoy en día, esa conexión es la base de lo que se conoce como Internet.

Desde entonces, Internet no ha hecho más que crecer y evolucionar, especialmente en los últimos años. Esto ha generado un interés creciente en mejorar la calidad del servicio (*QoS*) optimizando aspectos como la latencia, el ancho de banda y la fiabilidad, pues Internet se ha convertido en una parte fundamental de las vidas y del trabajo de las personas. Sin embargo, cuanto más se usa Internet, más recursos se necesitan para mantenerlo funcionando, lo que ha llevado a un aumento en el consumo de energía y, por ende, a un impacto ambiental significativo.

Aunque parezca que la preocupación por la sostenibilidad es algo reciente, la verdad es que lleva existiendo desde hace décadas. Por ejemplo, el 14 de marzo de 2001, el Parlamento Europeo adoptó una resolución sobre el impacto del consumo de energía y la necesidad de reducir este consumo en un 2.5 % anual, entre otras propuestas [4]. Otros estudios, como el de Paul J.M. Havinga y Gerard J.M. Smit [5], han analizado el consumo de energía en redes inalámbricas y dispositivos móviles, destacando la importancia de la

eficiencia en estos escenarios.

Es lógico mencionar el impacto ambiental cuando se habla de consumo energético, pues el término *intensidad de carbono* define la relación existente entre las emisiones de carbono producidas al generar un kWh de energía. Estas emisiones dependen en gran medida de las fuentes de energía utilizadas: como comenta José Antonio Gómez de la Hiz en su estudio [6], producir energía con carbón o gas natural emiten 950 y 450 gCO_2/kWh , respectivamente, mientras que usando fuentes renovables como el aire, las emisiones se reducen hasta los 15 gCO_2/kWh . Por tanto, si se consigue enrutar el tráfico por nodos cuyas fuentes de energía son "verdes" y reducir así la carga de aquellos enlaces pertenecientes a dispositivos ubicados en zonas de altas emisiones, se podría alcanzar una reducción de las emisiones totales de carbono de la red.

Uno de los grandes avances en redes que ha permitido mejorar la eficiencia energética es el desarrollo de las redes definidas por software (SDN) [7]. Las redes SDN y las redes tradicionales funcionan, esencialmente, de la misma manera: los dispositivos de red, como routers y switches, se encargan de dirigir el tráfico de datos hacia su destino. La diferencia fundamental entre ambos tipos de redes radica en cómo se gestionan y controlan estos dispositivos. En las redes tradicionales, cada dispositivo de red tiene integrado tanto el plano de control como el plano de datos, lo que significa que cada dispositivo toma sus propias decisiones sobre cómo manejar el tráfico. Por otro lado, las redes SDN separan el plano de control de los dispositivos y lo centralizan en lo que se denomina un controlador SDN. Este es el responsable de tomar decisiones sobre cómo debe dirigirse el tráfico y enviar estas instrucciones a los dispositivos de red, que se limitan a ejecutar las órdenes recibidas.

En la Figura 1.1 se muestra un sencillo esquema de cómo funcionan las redes SDN. En este esquema, se puede observar cómo el controlador SDN se comunica con los dispositivos de red para indicarles cómo deben manejar el tráfico de datos. Si bien esta separación entre el plano de control y el plano de datos puede parecer un cambio menor, en realidad tiene un impacto significativo en la eficiencia energética de las redes. Al centralizar el control, las redes SDN pueden optimizar el uso de los recursos de red en función del algoritmo

que esté ejecutándose en el controlador. Por ejemplo, si se quisiera reducir todo lo posible la carga de los enlaces, basta con definir e implementar un algoritmo que se centre en optimizar la redirección del tráfico para repartir equitativamente entre todos los enlaces todos los flujos de datos.




Figura 1.1: Representación gráfica de una red SDN.
Fuente: Elaboración propia.

El objetivo de este trabajo es reducir las emisiones de carbono de las redes cableadas SDN. Una posible solución podría ser el apagado de enlaces, pues apagar un enlace significa deshabilitar los puertos de los dispositivos que conecta. Si los enlaces que se apagan son aquellos que se encuentran en zonas de altas emisiones de carbono, se conseguiría reducir las emisiones totales de la red. Pero no basta solamente con apagar dichos enlaces, hay que tener en cuenta dos factores muy importantes: la conectividad de la red y la carga de los enlaces. De nada sirve reducir las emisiones si a cambio se aumenta considerablemente la latencia al sobrecargar los enlaces o se deja desconectado un nodo por apagar los enlaces que lo conectan a la red. Es aquí donde entra en juego el concepto de *enrutamiento consciente de carbono*. Este término se asemeja a la idea detrás del algoritmo que publicó Edsger W. Dijkstra en 1956, aunque en lugar de buscar el camino más corto, la idea es enrutar el tráfico a través del camino más "verde".

Al estar hablando de un problema de optimización, existen muchas técnicas que

podrían ser aplicadas para resolverlo. Como se busca una solución que ofrezca resultados lo suficientemente buenos en un tiempo razonable, las opciones a considerar se limitan bastante. En este caso, se ha optado por usar un algoritmo metaheurístico de optimización por enjambre de partículas (PSO), pues es un algoritmo que se ha demostrado eficaz en problemas de optimización similares y que, además, es relativamente sencillo de implementar.

En definitiva, para alcanzar el objetivo de este trabajo, se ha implementado un algoritmo basado en PSO que, dada una topología de red, busca la configuración de enlaces apagados y encendidos que minimice la emisiones de carbono de dicha red.

El resto de la memoria de este TFG se estructura de la siguiente forma: en el Capítulo 2 se habla sobre los objetivos generales y específicos, así como de las contribuciones realizadas. A lo largo del Capítulo 3 se explican diferentes conceptos y técnicas relacionados con el problema que se está tratando de resolver, mientras que en el Capítulo 4 se detalla la metodología seguida para la realización de este trabajo. El algoritmo que finalmente se ha desarrollado se detalla en el Capítulo 5, mientras que en el Capítulo 6 se presentan los resultados obtenidos de las pruebas realizadas. Finalmente, en el Capítulo 7, se presentan las conclusiones que se han sacado en claro de los resultados obtenidos, así como las líneas de trabajo futuras que se podrían seguir a partir de este trabajo.

Capítulo 2

Objetivos y Contribuciones

En este capítulo se detalla el objetivo principal planteado para el desarrollo de este trabajo, así como los objetivos específicos en los que se desglosa para poder alcanzar dicho propósito. Además, se presentan las contribuciones más relevantes que se han aportado tras la realización de este Trabajo de Fin de Grado (TFG).

2.1. Objetivos

El principal objetivo de este trabajo es proponer una solución que permita reducir las emisiones de CO_2 en redes cableadas provenientes del consumo energético de los dispositivos de red. Mediante el diseño de dos algoritmos, uno encargado del enrutamiento consciente de carbono y el otro del apagado eficiente de enlaces, se modifica la configuración de la red para que el consumo energético de sus dispositivos se centre en zonas de bajas emisiones y, por tanto, se reduzca la huella de carbono asociada a la infraestructura. Para ello, se han definido los siguientes objetivos específicos:

1. Análisis de datos y modelado de la red.
 - Identificar y procesar las fuentes de datos necesarias para modelar las redes cableadas y sus emisiones de CO_2 .
 - Representar la topología de red mediante estructuras de datos adecuadas, como matrices o listas, con las que trabajar a partir de archivos *csv* y *JSON*.



2. Estudio del apagado de enlaces.

- Investigar el funcionamiento de la técnica de apagado de enlaces para la reducción del consumo energético en redes SDN.
- Estudiar criterios y restricciones a tener en cuenta para el apagado de enlaces sin comprometer la conectividad o el rendimiento de la red.
- Analizar el impacto del apagado de enlaces sobre el enrutamiento del tráfico de datos y las emisiones de CO_2 .

3. Estudio de soluciones de enrutado conscientes de carbono.

- Estudiar diversas técnicas de encaminamiento del tráfico de datos.
- Analizar diferentes propuestas de enrutamiento conscientes de carbono.
- Estudiar cómo incorporar la información de las emisiones en el proceso de enrutamiento.

4. Desarrollo del algoritmo de optimización.

- Diseñar e implementar un algoritmo de PSO que se adapte a las características del problema planteado.
- Integrar técnicas de modularización y reutilización de código para facilitar el desarrollo y la escalabilidad del algoritmo de cara a futuras mejoras.

5. Validación y análisis de resultados.

- Hacer uso de topologías reales para evaluar el rendimiento del algoritmo desarrollado.
- Analizar los resultados obtenidos para determinar la efectividad del algoritmo en la reducción de emisiones de carbono.



2.2. Contribuciones

Tras la realización de este trabajo, se han aportado las contribuciones que a continuación se detallan:

-

Capítulo 3

Estado del Arte

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna.

Capítulo 4

Metodología

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna.

Capítulo 5

Descripción del Algoritmo Propuesto

En esta sección se presenta detalladamente la implementación del algoritmo desarrollado para abordar el objetivo de este trabajo, sus atributos y su evolución hasta llegar a la solución final.

5.1. Elección de la Técnica de Optimización

Como se ha visto en el apartado del estado del arte, los problemas de optimización se pueden abordar con diferentes técnicas dependiendo de las características del problema.

Una de las técnicas que ofrece soluciones óptimas, a costa de un gran tiempo de cómputo, es la programación lineal entera (ILP). El estudio *Networking for a Low-Carbon Future: An ILP-Based Carbon-Aware Approach for SDN* [6] muestra cómo esta técnica es capaz de reducir las emisiones de carbono en hasta un 84.5%, aunque el tiempo de ejecución llegó a alcanzar los 17 minutos, lo que es prohibitivo en escenarios tan cambiantes.

Como alternativa a soluciones basadas en ILP, se pueden usar técnicas de *Deep Learning* (DL). Pero estas técnicas, además de requerir una gran cantidad de datos para entrenar el modelo, no son viables para este tipo de problemas, pues en el momento en el que se modifique la topología de red, el modelo entrenado dejará de ser válido, lo que obligará a volver a entrenar el modelo desde cero, con la consecuente pérdida de tiempo

y recursos.

Los algoritmos genéticos pueden ser una buena opción, pero suelen requerir una considerable cantidad de tiempo de ejecución, especialmente para problemas con un gran espacio de búsqueda. Al estar tratando con un escenario en el que el tiempo es crítico, pues las necesidades de la red cambian a lo largo del día, las soluciones basadas en algoritmos genéticos no son factibles.

Por otro lado, los algoritmos voraces son rápidos y fáciles de implementar. Estas soluciones eliminan la problemática de los tiempos de ejecución largos que presentan las técnicas anteriores. Sin embargo, toman decisiones basadas únicamente en la información local sin considerar el impacto a largo plazo. Esto puede llevar a soluciones subóptimas o, incluso, a soluciones inviables si se toman decisiones que comprometen la conectividad de la red. Realmente, que un algoritmo voraz encuentre una solución subóptima no es algo inherentemente malo, pues ya se estaría hablando de una mejora significativa respecto a la situación inicial, pero el hecho de que pueda encontrar soluciones inviables es un riesgo que bajo ningún concepto se puede permitir.

En cambio, las soluciones basadas en PSO son una gran opción para este tipo de problemas, ya que son capaces de explorar el espacio de búsqueda de manera eficiente y encontrar soluciones, aunque no sean óptimas, en un tiempo razonable. Respecto a los algoritmos voraces, PSO ofrece la ventaja de ofrecer siempre soluciones factibles. Además, como PSO es un algoritmo de optimización global, tiene la capacidad de evitar caer en óptimos locales. Teniendo en cuenta que se tratan de problemas con grandes espacios de búsqueda, es fundamental evitar a toda costa los óptimos locales.

Otra ventaja de PSO es que existen numerosas implementaciones disponibles, lo que facilita su uso y permite centrarse en la modelización de la función objetivo. Además, PSO es un algoritmo relativamente sencillo de ajustar, con pocos parámetros a configurar, facilita la realización de barridos para encontrar la configuración que mejor se adapte al problema en cuestión.

Es por esto que se ha optado por usar PSO como técnica de optimización para abordar el problema de optimización de las emisiones de CO_2 en redes cableadas.

5.2. *Particle Swarm Optimization*

Como en la mayoría de algoritmos de optimización evolutivos, PSO se basa en la idea de iterar sobre un conjunto de soluciones candidatas, partículas, y actualizar estas soluciones en función de su rendimiento.




Figura 5.1: Diagrama de flujo de PSO.
Fuente: Elaboración propia.

Para entender mejor el diagrama de flujo que se muestra en la Figura 5.1, se va a usar un sencillo ejemplo: personas buscando una localización en un mapa.

1. PSO inicializa aleatoriamente el enjambre con un número determinado de partículas, que traducido al ejemplo, sería posicionar a las personas en el mapa de manera



aleatoria.

2. Luego, cada persona evalúa la calidad de su posición (cada partícula evalúa el fitness), es decir, cómo de cerca está de la localización objetivo.
3. A continuación, cada persona compara su posición actual con la mejor posición que ha encontrado hasta ese momento (p_best) y, en caso de ser superior, actualiza su mejor posición personal.
4. Después, los individuos se comunican entre sí para compartir información sobre sus mejores posiciones personales, lo que les permite conocer la mejor posición global encontrada por el grupo (g_best).
5. Si se ha alcanzado la condición de parada, como puede ser un número máximo de intentos, el grupo comunica la mejor posición global encontrada, que sería la localización más cercana al objetivo. Si no se ha alcanzado la condición de parada, cada persona, en función de la información recabada hasta el momento, se mueve a otra posición (actualizar velocidad y actualizar posición) y se vuelve a evaluar la calidad de su nueva posición, empezando así una nueva iteración.

5.3. Parámetros de PSO

En esta sección se detallan los parámetros que influyen en la ejecución de PSO, como pueden ser las partículas, el coeficiente de inercia, el coeficiente cognitivo, el coeficiente social, el número de vecinos y las dimensiones del espacio de búsqueda. Cada uno de estos parámetros tiene un impacto significativo en el rendimiento del algoritmo y en la calidad de las soluciones encontradas, por lo que es importante entender su función y cómo afectan al comportamiento del algoritmo.

5.3.1. Partícula

El concepto de partícula ya se ha comentado brevemente con anterioridad, y es que una partícula es un agente individual que representa una solución candidata al problema



de optimización. Como se ha comentado en el ejemplo anterior, se puede entender por partícula a una persona buscando la ubicación objetivo del mapa. De hecho, este ejemplo no se aleja mucho de la inspiración original de PSO, puesto que se basa en el comportamiento social de bandadas de pájaros o bancos de peces moviéndose en grupo hacia un objetivo común.

5.3.2. Función objetivo

La función objetivo es una parte fundamental de cualquier algoritmo de optimización, pues se trata de la función que se usa para evaluar cada solución candidata y determinar qué tan buena es esa solución. En el caso de PSO, la función objetivo se utiliza para evaluar la calidad de cada partícula en cada iteración, y se utiliza para actualizar la mejor posición personal de cada partícula y la mejor posición global del enjambre.

5.3.3. Velocidad

En PSO, las partículas tienen dos atributos principales, siendo la velocidad uno de ellos. Esta determina en qué dirección y cuánto se mueve cada partícula a lo largo del espacio de búsqueda. La velocidad se actualiza en cada iteración en función de la mejor posición personal de la partícula y la mejor posición global del enjambre, lo que permite que las partículas exploren el espacio de búsqueda de manera eficiente. Una velocidad alta puede permitir que las partículas exploren el espacio de búsqueda de manera más amplia, pero también puede hacer que el algoritmo sea más propenso a saltar sobre buenas soluciones. Por otro lado, una velocidad baja puede hacer que el algoritmo sea más lento, pero también puede ayudar a que las partículas se concentren en áreas prometedoras del espacio de búsqueda.

5.3.4. Posición

El segundo atributo principal de las partículas es la posición, que representa una posible solución al problema de optimización. La diferencia entre la posición y la partícula,



pues las definiciones pueden ser un poco confusas, es que la posición es el valor actual de la solución representada por la partícula, mientras que la partícula es el agente que se mueve a lo largo del espacio de búsqueda. Siguiendo con el ejemplo de las personas y el mapa, la posición sería el lugar específico donde se encuentra un individuo en un momento dado. La posición se actualiza en cada iteración en función de la velocidad de la partícula, lo que permite que las partículas se muevan a través del espacio de búsqueda y encuentren mejores soluciones.

5.3.5. Coeficiente de inercia

El coeficiente de inercia es un parámetro que controla la influencia de la velocidad anterior en la actualización de la velocidad actual de cada partícula. Un coeficiente de inercia alto hace que las partículas mantengan su velocidad anterior, lo que puede ayudar a que el algoritmo explore el espacio de búsqueda de manera más amplia. Por otro lado, un coeficiente de inercia bajo hace que las partículas sean más propensas a cambiar su velocidad en función de la mejor posición personal y global, lo que puede ayudar a que el algoritmo se concentre en áreas prometedoras. Es importante encontrar un valor adecuado para este parámetro en función del problema específico, ya que un valor demasiado alto o demasiado bajo puede afectar negativamente al rendimiento del algoritmo.

5.3.6. Coeficiente cognitivo

El coeficiente cognitivo es un parámetro que controla la influencia de la mejor posición personal de cada partícula en la actualización de su velocidad. Un coeficiente cognitivo alto hace que las partículas se centren más en su propia experiencia, lo que ayuda a que el algoritmo se centre en áreas prometedoras. Por otro lado, un coeficiente cognitivo bajo hace que las partículas sean más propensas a seguir la mejor posición global del enjambre, lo que puede ayudar a que el algoritmo explore el espacio de búsqueda más ampliamente.



5.3.7. Coeficiente social

El coeficiente social es un parámetro que controla la influencia de la mejor posición global del enjambre en la actualización de la velocidad de cada partícula. Un coeficiente social alto hace que las partículas se centren más en la experiencia colectiva del enjambre, lo que puede ayudar a que el algoritmo explore el espacio de búsqueda más ampliamente. Por otro lado, un coeficiente social bajo hace que las partículas sean más propensas a centrarse en su propia experiencia, así el algoritmo se concentra en áreas prometedoras. Es importante encontrar un equilibrio adecuado entre el coeficiente cognitivo y social, ya que un desequilibrio puede desembocar en soluciones subóptimas.

5.3.8. Número de vecinos

Este parámetro controla la cantidad de partículas que se consideran como vecinos de cada partícula en la actualización de su velocidad. Si el número de vecinos es alto, cada partícula se ve influenciada por un gran número de otras partículas, lo cual hace que se centre más en la experiencia colectiva del enjambre. En cambio, si el número de vecinos es bajo, cada partícula se ve influenciada por un número reducido de otras partículas, centrándose más en su propia experiencia.

5.3.9. Dimensiones del espacio de búsqueda

Este parámetro define el número de dimensiones que tiene el espacio de búsqueda, lo que a su vez determina la cantidad de variables que se están optimizando. Por lo general, cuantas más dimensiones tenga el espacio de búsqueda, más complejo será el problema de optimización, ya que habrá más variables a considerar, pero puede permitir encontrar mejores soluciones. Por el contrario, un espacio de búsqueda con pocas dimensiones puede ser más fácil de explorar, pero también puede limitar la calidad de las soluciones encontradas.

5.4. Aproximación al Problema

Con los conceptos básicos de PSO ya explicados, es importante entender cómo se ha aplicado este algoritmo al problema específico de optimización de las emisiones de CO_2 en redes SDN.

La primera solución que se planteó fue transformar el espacio discreto del problema en un espacio continuo, lo que permitiría usar PSO en su forma original. Sin embargo, esta aproximación terminó descartándose, pues la umbralización hacía que PSO trabajase a ciegas. Es decir, no era capaz de discernir entre los cambios que se producían por debajo del umbral, lo que se considera como un enlace apagado, por tanto PSO no sabía si esos cambios apuntaban a una mejora o a un empeoramiento de la solución, lo que generaba un comportamiento errático del algoritmo.




Figura 5.2: Representación gráfica de la función sigmoide.

Fuente: Elaboración propia.

Más adelante, se iteró sobre la idea anterior de transformar el espacio discreto en continuo, pero esta vez usando una función sigmoide para umbralizar a través del cálculo de la probabilidad de que un enlace esté activo o apagado. Sin embargo, y como se muestra en la Figura 5.2, se observó que, a medida que el valor continuo de la partícula, x , se aleja del cero, la curva se vuelve casi plana. Esto hace que, si el algoritmo decide que el enlace debe estar encendido, la velocidad de PSO empuje el valor de x hacia números positivos cada vez más altos. Pero si más tarde el algoritmo decide que ese enlace en realidad debe estar apagado, PSO tardará muchas iteraciones en generar una velocidad lo suficientemente negativa como para arrastrar el valor de x de vuelta al cero. En todo



ese tiempo, la partícula está estancada y pierde capacidad de exploración.

Finalmente, se optó por hacer uso de adaptaciones de PSO para espacios de búsqueda discretos. De esta manera, se evitan los problemas de "ceguera" de la umbralización y las pérdidas de capacidad de exploración que se observaban con la función sigmoide. Además, esto permite que PSO trabaje directamente con el espacio discreto del problema, mejorando así la eficiencia del algoritmo.

En el entorno de las redes SDN, la solución propuesta se implementaría en el controlador SDN, lo que permitiría a PSO tener acceso a información en tiempo real sobre el estado de la red y evaluar a lo largo del día los cambios que habría que hacer en cada momento para mantener las emisiones de CO_2 al mínimo.

5.4.1. Estrategias de manejo de restricciones

Para que el algoritmo sea realmente efectivo, se han de tener en cuenta las restricciones estrictas de la red, como pueden ser asegurar la conectividad total o no sobrepasar el ancho de banda. Para ello, se han evaluado dos aproximaciones de la función objetivo: PSO con penalización estricta y PSO con manejo de violación de restricciones.

PSO con penalización estricta

En esta variante, cuando una partícula propone una configuración de red que viola cualquiera de las restricciones, la función objetivo devuelve el valor infinito. En otras palabras, la posición de la partícula sufre una "muerte súbita", pues corta de golpe en el momento en el que no cumple una restricción.

La ventaja principal que presenta esta estrategia es la rapidez, pues el algoritmo descarta de manera inmediata una solución que no cumple con alguna restricción. Pero esta rapidez computacional le genera "ceguera" a PSO al no ser capaz de saber cuán buena es una solución inválida.

PSO con manejo de violación de restricciones

A diferencia de la variante anterior, el método *Violation Constraint Handling* (VCH) no descarta una solución de manera inmediata, sino que contabiliza la cantidad de veces que se ha violado alguna restricción (v) y la multiplica por un factor de penalización (P). Este valor se suma a las emisiones de CO_2 :

$$f_{fitness} = f_{emisiones} + v \cdot P \quad (5.1)$$

Este manejo más controlado de las violaciones proporciona a PSO un gradiente de información. De esta manera se puede discernir si una solución es menos mala que otra, lo que permite a las partículas atravesar zonas de inviabilidad para alcanzar regiones óptimas. Aunque es más lento que la versión anterior, puesto que el algoritmo debe realizar todos los cálculos para cada posición de cada partícula.

5.5. Implementación y Desarrollo del Algoritmo

En esta sección se usan las explicaciones realizadas en la sección anterior para definir el algoritmo que finalmente se ha desarrollado. Se detallan las decisiones tomadas durante el proceso de implementación, los desafíos encontrados y cómo se han abordado.

5.5.1. Configuración de las partículas

Como se ha comentado con anterioridad, una partícula representa una solución candidata al problema que se está tratando de optimizar. Siguiendo el ejemplo de las personas de la Sección 5.2, cada individuo representa una partícula evaluando las diferentes posiciones. En el caso de la optimización de las emisiones de CO_2 en redes SDN, cada partícula representa un agente que evalúa las diferentes posibles configuraciones de la red, es decir, diferentes combinaciones de enlaces encendidos y apagados.

Las partículas representan uno de los parámetros más importantes de PSO, pues su número y su configuración pueden afectar significativamente al rendimiento del algoritmo.

En este caso, se han configurado las partículas como vectores binarios, donde cada elemento del vector representa el estado de un enlace en la red, siendo 1 para un enlace encendido y 0 para un enlace apagado. En la Figura 5.3 se muestra una sencilla representación de una red como partícula de PSO.




Figura 5.3: Representación de una red sencilla como partícula de PSO.

Fuente: Elaboración propia.

La cantidad de partículas se ha establecido buscando un equilibrio entre la calidad de las soluciones encontradas y el tiempo de ejecución del algoritmo. Se han realizado varios barridos con la matriz de tráfico más cargada de la red Abilene, TM5, para averiguar cuál es el número más adecuado de partículas. Además, se aprovechó este mismo barrido para saber qué configuración de $c1$ y $c2$, coeficientes cognitivo y social, respectivamente, es la más eficiente. Los resultados que se obtuvieron en un primer momento son los que se pueden observar en la Figura 5.4. Apenas hay que analizar la gráfica para darse cuenta de que los resultados son erráticos y poco concluyentes.

De manera intuitiva, se podría pensar que a medida que se incrementa el número de partículas, la calidad de las soluciones encontradas debería mejorar, ya que el algoritmo tiene más agentes explorando el espacio de búsqueda. Sin embargo, como puede observarse en la gráfica, no se aprecia una tendencia clara, sino que los resultados mejoran y empeoran a medida que se incrementa la cantidad de partículas.




Figura 5.4: Resultados del barrido de partículas para la TM5 de Abilene. Iteraciones fijas en 1500.

Fuente: Elaboración propia.

Tras estos primeros resultados, se decidió investigar el por qué de los mismos. Tras la realización de diferentes pruebas, las cuales se comentarán con detalle más adelante en el Capítulo 6, se descubrió un factor que estaba afectando a los resultados de manera significativa: la aleatoriedad con la que se inician las partículas. Dado que PSO es un algoritmo estocástico, la inicialización aleatoria de las partículas puede llevar a resultados muy diferentes en cada ejecución, lo que explica la falta de una tendencia clara en los resultados del barrido. Para abordar este problema, se decidió inicializar las partículas de dos maneras: una de las partículas del enjambre se inicializa con todos los enlaces encendidos y el resto de partículas se inicializan con un porcentaje de enlaces encendidos que se comprende entre el 50 % y el 90 %.

En la Figura 5.5 se pueden observar los resultados del barrido de partículas con esta nueva estrategia de inicialización. En la gráfica se aprecia una clara tendencia a mejorar los resultados a medida que se incrementa el número de partículas, lo que confirma las sospechas sobre la influencia de la aleatoriedad en los resultados anteriores. Aunque todavía hay algún que otro pico, estos son despreciables en comparación con la mejora obtenida, pues disminuyen las emisiones entre 8 y 10 gCO_2 .





Figura 5.5: Resultados del barrido de partículas para la TM5 de Abilene con inicialización controlada de partículas. Iteraciones fijas en 1500.

Fuente: Elaboración propia.

Finalmente, se decidió usar 100 y 200 partículas para las pruebas finales. Por un lado, a partir de 200 partículas, las mejoras obtenidas no justificaban el incremento en el tiempo de ejecución. Por otro lado, aunque los resultados obtenidos con 100 partículas son ligeramente peores, la diferencia en el tiempo de ejecución es lo suficientemente alta como para justificar el uso de 100 partículas.

5.5.2. Iteraciones

Otro de los parámetros clave de PSO es el número de iteraciones, que determina cuántas veces las partículas tendrán que relizar el proceso de evaluación y actualización de sus posiciones. En general, un mayor número de iteraciones puede permitir que el algoritmo explore el espacio de búsqueda de manera más exhaustiva y encontrar mejores soluciones, pero también puede aumentar significativamente el tiempo de ejecución. Análogamente a lo que se hizo con las partículas, se realizaron dos barridos sobre la matriz TM5 de Abilene para averiguar cuál es el número de iteraciones más adecuado. Ambos barridos se realizaron desde 100 iteraciones hasta 1500, incrementando de 100 en 100, dejando fijas las partículas en 100 y 200, además de usar la misma estrategia de inicialización. También se aprovecharon estos barridos para averiguar qué configuración de $c1$ y $c2$ es la más eficiente.



(a) Barrido con partículas fijas en 100.
Fuente: Elaboración propia.

(b) Barrido con partículas fijas en 200.
Fuente: Elaboración propia.

Figura 5.6: Resultados de los barridos de iteraciones para la TM5 de Abilene con 100 y 200 partículas.

En los barridos mostrados en la Figura 5.6 se aprecia una clara tendencia a mejorar los resultados a medida que aumentan las iteraciones. En ambos casos, se observa que a partir de 600 iteraciones las mejoras que se obtienen son casi despreciables, por lo que se decidió fijar en 600 las iteraciones para las pruebas finales. De todas maneras, se decidió usar también 1200 iteraciones para comprobar si esta segunda configuración obtenía mejores resultados en escenarios más complejos, como pueden ser redes más grandes y con más tráfico.

Estas gráficas aportan información muy interesante sobre la influencia de las partículas en los resultados. En la Figura 5.6a, aunque todas las configuraciones de $c1$ y $c2$ mejoran los resultados al aumentar las iteraciones, se observa cierta disparidad entre las diferentes configuraciones. En cambio, en la Figura 5.6b, hay una mayor convergencia en los resultados obtenidos con las diferentes combinaciones de $c1$ y $c2$, lo que refuerza la decisión de usar 100 y 200 partículas para las pruebas finales.

5.5.3. Coeficientes cognitivo y social

Para determinar la configuración más adecuada de los coeficientes cognitivo y social, se aprovecharon los barridos realizados en las Subsecciones 5.5.1 y 5.5.2. En todos los barridos realizados, las configuraciones que ofrecían los mejores resultados eran aquellas

en las que el coeficiente social era mayor que el cognitivo, es decir, aquellas en las que las partículas se centraban más en la explotación que en la exploración. Concretamente, las dos mejores configuraciones era $c_1 = 1.5$ y $c_2 = 2.5$ (gráfica azul) y $c_1 = 1.75$ y $c_2 = 2.25$ (gráfica naranja). Puesto que desde un principio se quería buscar que el algoritmo se centrara más en la explotación, se terminó optando por la gráfica naranja, es decir, por la configuración $c_1 = 1.75$ y $c_2 = 2.25$, pues ofrece un buen equilibrio entre la exploración personal y la explotación colectiva, dando cierta prioridad a esta última.

5.5.4. Inercia, vecinos y dimensiones del espacio de búsqueda

Un valor coherente para que el coeficiente de inercia, representado por w , fomente que las partículas se centren más en la explotación que en la exploración, pero sin dejar de lado esta última, es 0.7. Lo que indica este valor es que para la siguiente iteración, a la hora de actualizar la velocidad, se tendrá en cuenta en un 70 % la velocidad de la iteración anterior. Esto permite a las partículas explotar los resultados grupales a buen ritmo pero deja margen de maniobra en caso de que estos resultados no terminen de ser fructíferos.

En el caso del número de vecinos, la cantidad fijada para todas las pruebas ha sido 100. Esto permite tener dos escenarios durante los experimentos: cuando el enjambre se componga de 100 partículas, cada una tendrá acceso a la información de todo el enjambre; cuando sea de 200, cada agente solo considerará la mitad. Estos dos escenarios son muy interesantes, ya que el primero favorece una rápida convergencia hacia la solución global, mientras que el segundo fomenta más la exploración.

Por último, las dimensiones del espacio de búsqueda dependen por completo de la topología de red, puesto que es el número de enlaces unidireccionales de la red lo que las define. Esto se debe a que cada partícula representa una solución candidata en la que se asigna un estado a cada enlace, por lo que el número de variables de dicha solución coincide directamente con el número de enlaces de la red. Por lo tanto, redes con mayor número de enlaces darán lugar a espacios de búsqueda más grandes, incrementando así la complejidad del problema.

5.5.5. Función objetivo y pseudocódigo

Para modelar la función que usará el algoritmo de PSO para evaluar la calidad de las posibles soluciones, se parte de la fórmula propuesta en el artículo *Exploring the Benefits of Carbon-Aware Routing* [2]:

$$C_{tot}(G, X, \lambda, c, \beta) = \sum_{n=1}^V (x_n * \lambda_n * c_n) + \sum_{l=1}^E \beta_l (c_{l_{n_1}} + c_{l_{n_2}}) \quad (5.2)$$

Donde:

- G es la topología de la red, representada como un grafo.
- V y E son el número de nodos y enlaces de la red, respectivamente.
- x_n es la intensidad de flujo en el nodo n .
- c_n es la tasa de emisiones de CO_2 asociada al nodo n .
- λ_n es la potencia dinámica incremental por tasa de datos del nodo n .
- β_l es el incremento del consumo de energía al habilitar un puerto.
- $c_{l_{n_1}}$ y $c_{l_{n_2}}$ son las emisiones de CO_2 asociadas a los nodos n_1 y n_2 que están conectados por el enlace l .

El primer sumatorio representa el consumo dinámico de energía asociado al tráfico que pasa por cada nodo, es decir, cuanto más tráfico pase por un nodo, más energía consumirá ese nodo. El segundo sumatorio se corresponde con el consumo estático de energía asociado a los enlaces que están activos. Un enlace activo implica que hay un puerto habilitado en cada uno de los nodos que conecta, lo que genera un consumo de energía adicional. La Figura 5.7 representa gráficamente lo que se acaba de explicar: la potencia estática es el consumo base de energía de un router y no se puede reducir. La potencia de los puertos es la cantidad de energía extra que se consume al habilitar un puerto. Este valor es orientativo, ya que el consumo real también depende del modo de operación en el que trabaje el router, puesto que cada modo influye en aspectos como la

velocidad de los datos. Por último, la componente azul del modelo es la potencia dinámica, que depende de la carga de tráfico del router.




Figura 5.7: Modelo de consumo de energía de un router.

Fuente: José Antonio Gómez de la Hiz [6].

A lo largo de este trabajo, se ha mencionado en varias ocasiones la importancia de no dejar sin conexión ninguna parte de la red. Si a eso se le junta querer reducir la carga de nodos y enlaces en zonas de altas emisiones, se genera la necesidad de buscar los caminos que cumplan ambos requisitos, necesidad que puede satisfacerse con la estrategia *K-Shortest Path* (KSP). Esta técnica permite encontrar los K caminos más cortos entre dos puntos, aunque en este caso los caminos no son los más cortos sino los más eficientes, ambientalmente hablando. De esta manera, si la ruta que menos emisiones genera no tiene capacidad de enrutar todo el tráfico, se evaluaría la siguiente ruta.

Una vez explicada en detalle la fórmula en la que se basa la función objetivo, se procede a presentar el pseudocódigo de la versión para PSO normal. El Algoritmo 1, dada una matriz de tráfico, asigna cada flujo al mejor camino disponible, procesando primero las demandas más grandes. Un camino se considera válido si solamente utiliza enlaces activos de la red y dispone de capacidad suficiente para satisfacer la demanda. Si algún flujo no puede ser asignado, la solución se considera inválida y se devuelve $+\infty$. Una vez asignados todos los flujos, se calcula la emisión de carbono tal y como se ha explicado con anterioridad: la potencia dinámica P_{dyn} , proporcional al tráfico en cada nodo, y la potencia de los puertos P_{ports} , asociada a los enlaces activos de la topología. Las emisiones totales de carbono de la red es el resultado de sumar ambos términos.

Algorithm 1 Cálculo de la emisiones totales de la red para PSO normal

Require: position[N][N], flow_matrix[N][N], all_k_paths, nodes_max_flow[N][N], carbon_intensity[N]

Ensure: Emisiones totales de carbono de la red

```

1: Inicializar nodes_traffic  $\leftarrow 0$ , links_traffic  $\leftarrow 0$ ,  $P_{\text{dyn}} \leftarrow 0$ ,  $P_{\text{ports}} \leftarrow 0$ 
2:  $\mathcal{A} \leftarrow \{(i, j) \mid \text{position}[i][j] = 1\}$ 
3: Ordenar demandas  $\mathcal{D}$  de forma descendente por flow_matrix[ $s$ ][ $d$ ]
4: for  $(s, d, \delta) \in \mathcal{D}$  do
5:    $p^* \leftarrow$  primer camino en all_k_paths[ $(s, d)$ ] válido y con capacidad  $\geq \delta$ 
6:   if  $p^* = \text{NONE}$  then return  $+\infty$ 
7:   end if
8:   Actualizar links_traffic y nodes_traffic según  $p^*$  y  $\delta$ 
9: end for
10: for  $x \leftarrow 0$  to  $N - 1$  do
11:    $c_x \leftarrow \text{carbon\_intensity}[x]/1000$ 
12:    $P_{\text{dyn}} += \text{nodes\_traffic}[x] \cdot \lambda_n \cdot c_x$ 
13:   for  $y \neq x$  con position[ $x$ ][ $y$ ]  $\neq 0$  do
14:      $P_{\text{ports}} += \beta_l \cdot (c_x + c_y)$ 
15:   end for
16: end for
17: return  $P_{\text{dyn}} + P_{\text{ports}}$ 

```

A continuación se presenta la variante del algoritmo anterior que introduce el mecanismo de penalización VCH. Cuando un flujo no puede ser asignado por ausencia de un camino válido o falta de capacidad, el Algoritmo 2 lo cuenta como una violación. Al finalizar la asignación, el número de violaciones se multiplica por un factor de penalización M y se añade a las emisiones de carbono. Esto permite que el algoritmo siempre devuelva un valor finito, penalizando las soluciones que incumplen las restricciones de la red.

Algorithm 2 Cálculo de la emisiones totales de la red para PSO VCH

Require: position[N][N], flow_matrix[N][N], all_k_paths, nodes_max_flow[N][N], carbon_intensity[N], M

Ensure: Intensidad de carbono total de la red, penalizada por violaciones

```

1: Inicializar nodes_traffic  $\leftarrow 0$ , links_traffic  $\leftarrow 0$ ,  $P_{\text{dyn}} \leftarrow 0$ ,  $P_{\text{ports}} \leftarrow 0$ ,  $v \leftarrow 0$ 
2:  $\mathcal{A} \leftarrow \{(i, j) \mid \text{position}[i][j] = 1\}$ 
3: Ordenar demandas  $\mathcal{D}$  de forma descendente por flow_matrix[ $s$ ][ $d$ ]
4: for  $(s, d, \delta) \in \mathcal{D}$  do
5:    $p^* \leftarrow$  primer camino en all_k_paths[ $(s, d)$ ] válido y con capacidad  $\geq \delta$ 
6:   if  $p^* = \text{NONE}$  then
7:      $v += 1$  ▷ Contabilizar violación y continuar
8:   else
9:     Actualizar links_traffic y nodes_traffic según  $p^*$  y  $\delta$ 
10:  end if
11: end for
12: for  $x \leftarrow 0$  to  $N - 1$  do
13:    $c_x \leftarrow \text{carbon\_intensity}[x]/1000$ 
14:    $P_{\text{dyn}} += \text{nodes\_traffic}[x] \cdot \lambda_n \cdot c_x$ 
15:   for  $y \neq x$  con position[ $x$ ][ $y$ ]  $\neq 0$  do
16:      $P_{\text{ports}} += \beta_l \cdot (c_x + c_y)$ 
17:   end for
18: end for
19: return  $P_{\text{dyn}} + P_{\text{ports}} + v \cdot M$ 

```

Capítulo 6

Pruebas y Resultados

A lo largo de este capítulo se presentan las pruebas realizadas para evaluar el rendimiento del algoritmo, así como los resultados obtenidos y su análisis. Además, se detalla la configuración final del algoritmo, donde se explican las librerías utilizadas y otros aspectos relevantes como las especificaciones del ordenador en el que se han realizado las pruebas.

6.1. Detalles de la implementación

Para la implementación del algoritmo desarrollado, se ha hecho uso del lenguaje de programación Python, debido a su versatilidad y a la gran cantidad de librerías disponibles para el desarrollo de algoritmos de optimización y análisis de datos. Además, es el mismo lenguaje que se ha utilizado por parte del co-tutor, José Antonio Gómez de la Hiz, en sus investigaciones en el mismo ámbito, lo que ha sido de gran ayuda.

Inicialmente se valoraron dos herramientas para el desarrollo del algoritmo: Visual Studio Code y PyCharm. Finalmente se optó por PyCharm, puesto que ofrece diferentes funcionalidades que facilitan en gran medida el desarrollo de código, como pueden ser la integración de sistemas de control de versiones, la depuración de código o la gestión de entornos virtuales.

En cuanto a las librerías, se han utilizado principalmente las siguientes:



- NumPy: para el manejo de arrays y matrices, así como carga de datos desde archivos de texto o *csv*.
- NetworkX: para la creación y manipulación de grafos, fundamental para poder modelar las topologías de red usadas.
- Matplotlib: para la visualización de resultados y gráficos.
- PySwarms: para el uso de algoritmos de PSO en espacios discretos.
- SciPy: para cálculos estadísticos adicionales, como los intervalos de confianza.

PySwarms permite usar paralelización para acelerar el proceso de evaluación de las partículas, lo que ha sido de gran ayuda para reducir el tiempo de ejecución del algoritmo. Aunque la CPU presente *hyper-threading*, Python solo es capaz de correr en paralelo tantos procesos como núcleos tenga el procesador, es decir, si el ordenador tiene una CPU de 6 núcleos y 12 hilos, por mucho que se hayan creado 40 procesos, solamente 6 se ejecutan a la vez. Aún así, la paralelización de PySwarms ha permitido aprovechar al máximo la capacidad de la CPU y reducir significativamente los tiempos de ejecución.

Todas las pruebas y experimentos realizados se han llevado a cabo en un ordenador con las siguientes especificaciones:

- CPU: AMD Ryzen 5 3600x (6 núcleos, 12 hilos, frecuencia base de 3.8 GHz y frecuencia turbo de 4.4 GHz).
- GPU: AMD Radeon RX 7900 GRE (16GB GDDR6)
- RAM: 32GB DDR4 a 3200MT/s CL16

6.2. Topologías utilizadas

Para poder realizar las pruebas, se han utilizado diferentes topologías de red reales, cuya información se ha obtenido a través de la web SNDlib [8]. Estas topologías se han seleccionado para cubrir diferentes escenarios y tamaños de red, lo que permite evaluar el



rendimiento del algoritmo y su viabilidad en el mundo real. Las topologías usadas son las de Abilene, Nobel-Germany, Geant y Germany-50.

Abilene es la red más pequeña de las cuatro, con 12 nodos y 30 enlaces unidireccionales. Es la red que se ha usado en el Capítulo 5 para realizar los barridos de partículas e iteraciones. El uso de esta red ha facilitado la realización de pruebas rápidas para analizar cómo se comportaba el algoritmo en las diferentes fases del desarrollo. Geant y Nobel-EU son redes de tamaño medio, con 22 nodos y 72 enlaces unidireccionales, y 17 nodos y 52 enlaces unidireccionales, respectivamente. Estas redes han servido para evaluar el rendimiento del algoritmo en escenarios más complejos que el de Abilene y comprobar la viabilidad de la solución, o de alguna modificación de esta, en redes del mismo tamaño o parecidas. Finalmente, Germany-50 es la red más grande de las cuatro, con 50 nodos y 176 enlaces unidireccionales. Al duplicar el tamaño de la red con respecto a las dos anteriores, se obtiene un escenario con una complejidad lo suficientemente alta, lo cual permite evaluar la escalabilidad del algoritmo y su rendimiento en redes más grandes.

6.3. Definición de las pruebas

Con las topologías seleccionadas, se han definido diferentes pruebas para evaluar el rendimiento del algoritmo. Estas pruebas consisten en, usando KSP como técnica de enrutamiento, ejecutar el algoritmo con las diferentes configuraciones de parámetros y estrategias de manejo de restricciones que se han definido a lo largo del Capítulo 5. Para cada matriz de tráfico, se han realizado 20 y 100 ejecuciones del algoritmo para obtener resultados representativos. Con 20 ejecuciones se obtiene una visión general del comportamiento del algoritmo más fácilmente que con 100 ejecuciones, mientras que con esta segunda cantidad de ejecuciones se obtienen resultados, estadísticamente hablando, más exactos y con unos intervalos de confianza más ajustados, los cuales se han calculado usando la distribución normal estándar al tratarse de una muestra lo suficientemente grande. Para las pruebas de 20 ejecuciones se emplea la distribución T de Student, que es más adecuada para muestras pequeñas.

6.4. Resultados de Abilene

A continuación, se muestran diferentes gráficas elaboradas a partir de los resultados obtenidos de las pruebas realizadas sobre Abilene. Esta topología es una infraestructura de red situada en Estados Unidos que interconecta universidades y centros de investigación. Como se muestra en la Figura 6.1, se compone de 12 nodos y 30 enlaces unidireccionales.



Figura 6.1: Topología de Abilene.
Fuente: SNDlib.

6.4.1. Emisiones de cada matriz de tráfico

Previo a mostrar los resultados obtenidos de las pruebas realizadas, es importante conocer cuáles son las emisiones de la red con todos los enlaces encendidos para poder evaluar correctamente las mejoras alcanzadas. En la Figura 6.2 se puede observar que las emisiones de la red son mayores a medida que aumenta el tráfico, pues el grado de utilización de los enlaces es un factor que influye bastante. Un detalle a tener en cuenta es que las emisiones mostradas en la gráfica no comienzan en cero, esto se ha hecho para observar claramente las diferencias entre cada matriz de tráfico.




Figura 6.2: Emisiones de Abilene con todos los enlaces encendidos.
Fuente: Elaboración propia.

6.4.2. Emisiones después del apagado de enlaces

Las primeras pruebas que se realizaron con Abilene arrojaron unos resultados realmente prometedores. Haciendo uso de PSO normal con 200 partículas, 1200 iteraciones y 20 ejecuciones por cada matriz de tráfico, se han reducido las emisiones en hasta un 38.44 %. Además, como se muestra en la Figura 6.3, los intervalos de confianza son muy estrechos, lo que indica que con 20 ejecuciones el algoritmo presenta poca variabilidad y converge hacia soluciones de calidad.




Figura 6.3: Emisiones de Abilene tras ejecutar PSO normal 20 veces por TM con 200 partículas y 1200 iteraciones. Intervalos de confianza al 95 %
Fuente: Elaboración propia.

Al ejecutar el algoritmo 100 veces por cada matriz de tráfico con la misma configuración, los resultados que se muestran en la Figura 6.4 son básicamente idénticos que los obtenidos en la prueba anterior. Lo único que cambia son los intervalos de confianza, que son aún más estrechos, lo que confirma el buen funcionamiento del algoritmo y su convergencia hacia soluciones de calidad.




Figura 6.4: Emisiones de Abilene tras ejecutar PSO normal 100 veces por TM con 200 partículas y 1200 iteraciones. Intervalos de confianza al 95 %

Fuente: Elaboración propia.

Tras estas primeras pruebas, se repitieron los experimentos manteniendo la configuración pero esta vez usando PSO VCH. Los resultados usando esta segunda estrategia son sorprendentes, pues se consigue una mejora de hasta un 20.80 % con respecto a PSO normal. En la Figura 6.5 se muestran estos incrementos de calidad en las soluciones, donde, además, se pueden observar unos intervalos de confianza muy estrechos, reforzando una vez más la estabilidad del algoritmo.






Figura 6.5: Emisiones de Abilene tras ejecutar PSO VCH 20 veces por TM con 200 partículas y 1200 iteraciones. Intervalos de confianza al 95 %
Fuente: Elaboración propia.

Estas mejoras al usar PSO VCH con 200 partículas y 1200 iteraciones, inevitablemente plantean diferentes cuestiones: si se reducen las partículas a 100 ¿cuánto mejoran los tiempos de ejecución? ¿Se mantendría la calidad de los resultados? ¿Y si además se reducen las iteraciones a 600? Todas estas preguntas se responden durante las dos siguientes pruebas: primero, se redujeron las partículas a 100 manteniendo las 1200 iteraciones, y posteriormente, las iteraciones se fijaron en 600.



(a) Emisiones para 1200 iteraciones y 100 partículas.

Fuente: Elaboración propia.



(b) Emisiones para 600 iteraciones y 100 partículas.

Fuente: Elaboración propia.

Figura 6.6: Emisiones de Abilene tras ejecutar PSO VCH 20 veces por TM modificando partículas e iteraciones. Intervalos de confianza al 95 %

Los resultados de estas dos pruebas pueden verse en la Figura 6.6. Aunque las emisiones son ligeramente más altas que con 200 partículas, siguen siendo soluciones de buena calidad. Además, los intervalos de confianza están bastante ajustados, lo cual indica que el comportamiento del algoritmo reduciendo a la mitad tanto el número de partículas como la cantidad de iteraciones, sigue presentando muy poca variabilidad y mantiene su tendencia a soluciones de calidad. La mejora más significativa reside en los tiempos de ejecución, pero esto se verá en detalle más adelante en la Subsección 6.4.3.

Por último, en la figura X se presenta una gráfica final donde se muestran los resultados obtenidos con anterioridad, así como las emisiones de Abilene con todos los enlaces encendidos. De esta manera, de un solo vistazo se pueden comparar todos los resultados y observar las mejoras que se obtienen con cada configuración.

6.4.3. Tiempos de ejecución




Figura 6.7: Tiempos de ejecución de Abilene. Intervalos de confianza al 95 %

Fuente: Elaboración propia.



6.4.4. Porcentaje de enlaces apagados

6.4.5. Ocupación de los enlaces tras el apagado

6.5. Resultados de Nobel y Geant

6.6. Análisis de Germany y limitaciones encontradas

Capítulo 7

Conclusiones y Trabajos Futuros

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna.

Anexos

Anexo A

Acrónimos

- IA (Inteligencia Artificial)
- SDN (*Software Defined Network*)
- PSO (*Particle Swarm Optimization*)
- QoS (*Quality of Service*)
- TFG (Trabajo de Fin de Grado)
- API (*Application Programming Interface*)
- KSP (*K-Shortest Path*)
- ILP (*Integer Linear Programming*)
- DL (*Deep Learning*)
- VCH (*Violation Constraint Handling*)
- TM (Matriz de Tráfico)

Bibliografía

- [1] Daniel Paska, Nina Lövehagen, Ove Persson, and Jens Malmödin. ICT energy evolution: Telecom, data centers, and AI. White paper, Ericsson, 2025. URL: <https://www.ericsson.com/en/reports-and-papers/white-papers/ict-energy-evolution-telecom-data-centers-and-ai>.
- [2] Sawsan El-Zahr, Paul Gunning, and Noa Zilberman. Exploring the benefits of carbon-aware routing. *Proceedings of the ACM on Networking*, 1(CoNEXT3):1–24, 2023. doi:10.1145/3629165.
- [3] V. Rajaraman. A concise history of the Internet. *Resonance*, 27:1841–1856, 2022. doi:10.1007/s12045-022-1483-2.
- [4] European Parliament. Resolution on the commission communication on the action plan to improve energy efficiency in the European Community. P5_TA(2001)0141, 3 2001. Document A5-0054/2001. Procedure 2000/2265(COS). URL: https://www.europarl.europa.eu/doceo/document/TA-5-2001-0141_EN.html.
- [5] Paul J. M. Havinga and Gerard J. M. Smit. Energy-efficient wireless networking for multimedia applications. *Wireless Communications and Mobile Computing*, 1(2):165–184, 2001. doi:10.1002/wcm.9.
- [6] Jose Gómez-delaHiz and Jaime Galán-Jiménez. Networking for a low-carbon future: An ILP-based carbon-aware approach for SDN. In *2025 16th International Conference on Network of the Future (NoF)*, pages 191–199, 2025. URL: <https://ieeexplore.ieee.org/abstract/document/11223308>, doi:10.1109/NoF66640.2025.11223308.

- [7] Suchismita Rout, Kshira Sagar Sahoo, Sudhansu Sekhar Patra, Bibhudatta Sahoo, and Deepak Puthal. Energy efficiency in software defined networking: A survey. *SN Computer Science*, 2(308), 2021. doi:[10.1007/s42979-021-00659-9](https://doi.org/10.1007/s42979-021-00659-9).
- [8] Sebastian Orlowski, Roland Wessäly, Michal Pióro, and Artur Tomaszewski. SNDLIB 1.0—survivable network design library. *Networks: An International Journal*, 55(3):276–286, 2010. URL: <https://sndlib.put.poznan.pl/home.action>, doi:[10.1002/net.20371](https://doi.org/10.1002/net.20371).